

UFOP/ICEB/DEEST
EST022 - Estatística Multivariada II
Prof. Tiago Martins Pereira

Estimadores de Máxima Verossimilhança para o vetor de
médias e matriz de covariâncias

Antes de encontrarmos os estimadores de máxima verossimilhança para os parâmetros da distribuição normal multivariada, temos que nos atentar aos seguintes resultados:

Resultado 01: Regras de derivação em relação à vetores e matrizes.

$$\text{a) } \frac{\partial \left[\sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) \right]}{\partial \boldsymbol{\mu}} = -2 \sum_{j=1}^n \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu})$$

$$\text{b) } \frac{\partial \ln |\boldsymbol{\Sigma}|}{\partial \boldsymbol{\Sigma}} = (\boldsymbol{\Sigma}^{-1})^t$$

$$\text{c) } \frac{\partial \text{tr}(\boldsymbol{\Sigma}^{-1} \mathbf{A})}{\partial \boldsymbol{\Sigma}} = -\boldsymbol{\Sigma}^{-1} \mathbf{A} \boldsymbol{\Sigma}^{-1}$$

Resultado 02: Sejam \mathbf{A} uma matriz simétrica ($k \times k$) e \mathbf{x} um vetor ($k \times 1$). Então,

$$\text{a) } \mathbf{x}^t \mathbf{A} \mathbf{x} = \text{tr}(\mathbf{x}^t \mathbf{A} \mathbf{x}) = \text{tr}(\mathbf{A} \mathbf{x} \mathbf{x}^t)$$

$$\text{b) } \text{tr}(\mathbf{A}) = \sum_{i=1}^k \lambda_i, \text{ em que } \lambda_i \text{ são os autovalores de } \mathbf{A}.$$

Demonstração: Seja $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma amostra aleatória de uma distribuição $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. A função de verossimilhança para o modelo normal multivariado é dado por:

$$L(\mathbf{X}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{np/2} |\boldsymbol{\Sigma}|^{n/2}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) \right\}$$

Para encontrarmos os estimadores de máxima verossimilhança para o vetor de médias e matriz de covariâncias, basta tomarmos as derivadas parciais de primeira ordem da função de verossimilhança em relação a cada parâmetro e igualarmos as funções obtidas a zero. Para isso, vamos tomar o logaritmo da função de verossimilhança e maximizar a função resultante, conhecida como função suporte. Este artifício é utilizado para facilitar o encontro dos estimadores. Uma vez que a função logarítmica é monótona crescente, os máximos das funções de verossimilhança e suporte são exatamente os mesmos.

Seja então a função suporte:

$$\begin{aligned}
g(\mathbf{X}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \ln[L(\mathbf{X}; \boldsymbol{\mu}, \boldsymbol{\Sigma})] \\
&= \ln \left[\prod_{j=1}^n f_{\mathbf{X}}(\mathbf{X}_j) \right] \\
&= \ln \left[(2\pi)^{-\frac{np}{2}} |\boldsymbol{\Sigma}|^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) \right\} \right] \\
&= \ln(2\pi)^{-\frac{np}{2}} + \ln |\boldsymbol{\Sigma}|^{-\frac{n}{2}} + \ln \left[\exp \left\{ -\frac{1}{2} \sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) \right\} \right] \\
&= -\frac{np}{2} \ln(2\pi) - \frac{n}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu})
\end{aligned}$$

De forma que, derivando a função suporte em relação ao parâmetro $\boldsymbol{\mu}$, utilizando a regra apresentada na alínea a) do Resultado 01:

$$\begin{aligned}
\frac{\partial g(\mathbf{X}; \boldsymbol{\mu}, \boldsymbol{\Sigma})}{\partial \boldsymbol{\mu}} &= \frac{\partial \left\{ -\frac{np}{2} \ln(2\pi) - \frac{n}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{j=1}^n [(\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu})] \right\}}{\partial \boldsymbol{\mu}} \\
&= -\frac{1}{2} (-2) \sum_{j=1}^n \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) \\
&= \sum_{j=1}^n \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) \\
&= \boldsymbol{\Sigma}^{-1} \sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu})
\end{aligned}$$

Igualando a zero:

$$\begin{aligned}
\hat{\Sigma}^{-1} \sum_{j=1}^n (\mathbf{X}_j - \hat{\boldsymbol{\mu}}) = \mathbf{0} &\Rightarrow \sum_{j=1}^n (\mathbf{X}_j - \hat{\boldsymbol{\mu}}) = \mathbf{0} \\
&\Rightarrow \sum_{j=1}^n (\mathbf{X}_j - \hat{\boldsymbol{\mu}}) = \mathbf{0} \\
&\Rightarrow \sum_{j=1}^n \mathbf{X}_j - \sum_{j=1}^n \hat{\boldsymbol{\mu}} = \mathbf{0} \\
&\Rightarrow \sum_{j=1}^n \mathbf{X}_j - n\hat{\boldsymbol{\mu}} = \mathbf{0} \\
&\Rightarrow \sum_{j=1}^n \mathbf{X}_j = n\hat{\boldsymbol{\mu}} \quad \therefore \quad \boldsymbol{\mu} = \frac{\sum_{j=1}^n \mathbf{X}_j}{n} = \bar{\mathbf{X}}
\end{aligned}$$

■

O expoente da função de verossimilhança pode ser simplificado. De acordo com a alínea *a*) do Resultado 02, temos,

$$\begin{aligned}
(\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) &= \text{tr} [(\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu})] \\
&= \text{tr} [\boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) (\mathbf{X}_j - \boldsymbol{\mu})^t]
\end{aligned}$$

em seguida,

$$\begin{aligned}
\sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) &= \sum_{j=1}^n \text{tr} [(\mathbf{X}_j - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu})] \\
&= \sum_{j=1}^n \text{tr} [\boldsymbol{\Sigma}^{-1} (\mathbf{X}_j - \boldsymbol{\mu}) (\mathbf{X}_j - \boldsymbol{\mu})^t] \\
&= \text{tr} \left[\boldsymbol{\Sigma}^{-1} \left(\sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu}) (\mathbf{X}_j - \boldsymbol{\mu})^t \right) \right]
\end{aligned}$$

uma vez que o traço da soma é igual à soma dos traços. Somando e subtraindo $\bar{\mathbf{X}}$ de cada termo $(\mathbf{X}_j - \boldsymbol{\mu})$ em $\sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu}) (\mathbf{X}_j - \boldsymbol{\mu})^t$, temos,

$$\begin{aligned}
\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}} + \bar{\mathbf{X}} - \boldsymbol{\mu}) (\mathbf{X}_j - \bar{\mathbf{X}} + \bar{\mathbf{X}} - \boldsymbol{\mu})^t &= \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \\
&+ 2 \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t \\
&+ \sum_{j=1}^n (\bar{\mathbf{X}} - \boldsymbol{\mu}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t
\end{aligned}$$

Uma vez que a matriz de produtos cruzados $\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t$ é uma matriz nula, temos,

$$\sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu}) (\mathbf{X}_j - \boldsymbol{\mu})^t = \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t + n (\bar{\mathbf{X}} - \boldsymbol{\mu}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t$$

Assim, podemos reescrever a função suporte,

$$\begin{aligned}
g(\mathbf{X}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= -\frac{np}{2} \ln(2\pi) - \frac{n}{2} \ln |\boldsymbol{\Sigma}| \\
&- \frac{1}{2} \text{tr} \left[\boldsymbol{\Sigma}^{-1} \left(\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t + n (\bar{\mathbf{X}} - \boldsymbol{\mu}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t \right) \right] \\
&= -\frac{np}{2} \ln(2\pi) - \frac{n}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} \text{tr} \left[\boldsymbol{\Sigma}^{-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \right] \\
&- \frac{1}{2} \text{tr} \left[n \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t \right]
\end{aligned}$$

Derivando em relação a $\boldsymbol{\Sigma}$, utilizando as alíneas *b*) e *c*) do Resultado 02, encontramos o estimador de máxima verossimilhança para $\boldsymbol{\Sigma}$:

$$\begin{aligned}
\frac{\partial g(\mathbf{X}; \boldsymbol{\mu}, \boldsymbol{\Sigma})}{\partial \boldsymbol{\Sigma}} &= \frac{\partial \left[-\frac{np}{2} \ln(2\pi) - \frac{n}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} \text{tr} \left[\boldsymbol{\Sigma}^{-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \right] - \frac{1}{2} \text{tr} \left[n \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t \right] \right]}{\partial \boldsymbol{\Sigma}} \\
&= -\frac{n}{2} (\boldsymbol{\Sigma}^{-1})^t + \frac{1}{2} \boldsymbol{\Sigma}^{-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \boldsymbol{\Sigma}^{-1} \\
&+ \frac{n}{2} \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}
\end{aligned}$$

Igualando a zero:

$$\begin{aligned}
-\frac{n}{2}(\hat{\Sigma}^{-1})^t &+ \frac{1}{2}\hat{\Sigma}^{-1}\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \hat{\Sigma}^{-1} + \frac{n}{2}\hat{\Sigma}^{-1}(\bar{\mathbf{X}} - \hat{\boldsymbol{\mu}})(\bar{\mathbf{X}} - \hat{\boldsymbol{\mu}})^t \hat{\Sigma}^{-1} = \mathbf{0} \\
-n\hat{\Sigma}^{-1} &+ \hat{\Sigma}^{-1}\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \hat{\Sigma}^{-1} + n\hat{\Sigma}^{-1}(\bar{\mathbf{X}} - \hat{\boldsymbol{\mu}})(\bar{\mathbf{X}} - \hat{\boldsymbol{\mu}})^t \hat{\Sigma}^{-1} = \mathbf{0} \\
-n\hat{\Sigma}^{-1} &+ \hat{\Sigma}^{-1}\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \hat{\Sigma}^{-1} + n\hat{\Sigma}^{-1}(\bar{\mathbf{X}} - \bar{\mathbf{X}})(\bar{\mathbf{X}} - \bar{\mathbf{X}})^t \hat{\Sigma}^{-1} = \mathbf{0} \\
-n\hat{\Sigma}^{-1} &+ \hat{\Sigma}^{-1}\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \hat{\Sigma}^{-1} = \mathbf{0} \\
-n\hat{\Sigma}\hat{\Sigma}^{-1}\hat{\Sigma} &+ \hat{\Sigma}\hat{\Sigma}^{-1}\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \hat{\Sigma}^{-1}\hat{\Sigma} = \mathbf{0} \\
n\hat{\Sigma} &= \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \\
\hat{\Sigma} &= \frac{1}{n}\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t = \frac{(n-1)}{n}\mathbf{S} = \mathbf{S}_n
\end{aligned}$$

■

Podemos reescrever a função de verossimilhança da seguinte maneira:

$$\mathbf{L}(\mathbf{X}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = (2\pi)^{-\frac{np}{2}} |\boldsymbol{\Sigma}|^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} \text{tr} \left[\boldsymbol{\Sigma}^{-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})^t \right] - \frac{1}{2} \text{tr} \left[n\boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) (\bar{\mathbf{X}} - \boldsymbol{\mu})^t \right] \right\}$$

Substituindo os valores de $\hat{\boldsymbol{\mu}}$ e $\hat{\boldsymbol{\Sigma}}$ na função de verossimilhança, encontramos seu máximo:

$$\begin{aligned}
\mathbf{L}_{\Omega}(\mathbf{X}; \hat{\boldsymbol{\mu}}, \hat{\boldsymbol{\Sigma}}) &= (2\pi)^{-\frac{np}{2}} |\mathbf{S}_n|^{-\frac{n}{2}} \exp \left\{ \frac{-\text{tr} [n\mathbf{S}_n^{-1}\mathbf{S}_n] - \text{tr} [n\mathbf{S}_n^{-1}(\bar{\mathbf{X}} - \bar{\mathbf{X}})(\bar{\mathbf{X}} - \bar{\mathbf{X}})^t]}{2} \right\} \\
&= (2\pi)^{-\frac{np}{2}} |\mathbf{S}_n|^{-\frac{n}{2}} \exp \left\{ -\frac{np}{2} \right\}
\end{aligned}$$

em que Ω representa o espaço paramétrico irrestrito.

■