

UFOP/ICEB/DEEST
EST022 - Estatística Multivariada II
Prof. Tiago Martins Pereira

Máximo da função de verossimilhança para o modelo
restrito: $\Sigma_1 = \Sigma_2 = \dots = \Sigma_K = \Sigma$

Demonstração: Considere amostras aleatórias $K \geq 2$ populações normais p -variadas $N_p(\mu_k, \Sigma_k)$ de tamanho n_k , $k = 1, \dots, K$. A amostra da k -ésima população é dada por $\mathbf{X}_{k1}, \mathbf{X}_{k2}, \dots, \mathbf{X}_{kn_k}$, em que $\mathbf{X}_{kj} \in \mathbb{R}^p$ corresponde à j -ésima unidade da k -ésima população. Considere também que $n = \sum_{k=1}^K n_k$.

O nosso interesse é testar:

$$H_0 : \Sigma_1 = \Sigma_2 = \dots = \Sigma_K = \Sigma \quad \text{vs} \quad H_a : \text{pelo menos uma difere}$$

Temos que, a função de verossimilhança para o modelo irrestrito é dada por:

$$L_{\Omega}(\mathbf{X}; \mu_k, \Sigma_k) = (2\pi)^{-\frac{np}{2}} \prod_{k=1}^K |\Sigma_k|^{-\frac{n_k}{2}} \exp \left\{ -\frac{1}{2} \sum_{k=1}^K \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \mu_k)^t \Sigma_k^{-1} (\mathbf{X}_{kj} - \mu_k) \right\}$$

de forma que a função suporte será dada por:

$$g(\mathbf{X}; \mu_k, \Sigma_k) = -\frac{np}{2} \ln(2\pi) - \sum_{k=1}^K \frac{n_k}{2} \ln |\Sigma_k| - \frac{1}{2} \sum_{k=1}^K \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \mu_k)^t \Sigma_k^{-1} (\mathbf{X}_{kj} - \mu_k)$$

Utilizando os mesmos passos algébricos mostrados anteriormente, podemos mostrar que a expressão

$$\sum_{k=1}^K \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \mu_k)^t \Sigma_k^{-1} (\mathbf{X}_{kj} - \mu_k)$$

pode ser reescrita como

$$\sum_{k=1}^K \text{tr}[(n_k - 1) \Sigma_k^{-1} \mathbf{S}_k + n_k \Sigma_k^{-1} (\bar{\mathbf{X}}_k - \mu_k)(\bar{\mathbf{X}}_k - \mu_k)^t],$$

em que a matriz

$$\mathbf{S}_k = \frac{1}{n_k - 1} \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \bar{\mathbf{X}}_k)(\mathbf{X}_{kj} - \bar{\mathbf{X}}_k)^t$$

representa o estimador não-viesado da covariância para a k -ésima população. Temos então que a função suporte pode ser reescrita como:

$$g(\mathbf{X}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = -\frac{np}{2} \ln(2\pi) - \sum_{k=1}^K \frac{n_k}{2} \ln |\boldsymbol{\Sigma}_k| - \frac{1}{2} \sum_{k=1}^K \text{tr}[(n_k - 1) \boldsymbol{\Sigma}_k^{-1} \mathbf{S}_k] - \frac{1}{2} \sum_{k=1}^K \text{tr}[n_k \boldsymbol{\Sigma}_k^{-1} (\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)(\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)^t]$$

Derivando a função g em relação a $\boldsymbol{\mu}_k$, temos:

$$\frac{\partial g}{\partial \boldsymbol{\mu}_k} = n_k \boldsymbol{\Sigma}_k^{-1} (\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k), \quad \text{para } k = 1, \dots, K$$

Igualando a zero, temos o estimador de máxima verossimilhança para $\boldsymbol{\mu}_k$:

$$\begin{aligned} \frac{\partial g}{\partial \boldsymbol{\mu}_k} = \mathbf{0} &\Rightarrow n_k \boldsymbol{\Sigma}_k^{-1} (\bar{\mathbf{X}}_k - \hat{\boldsymbol{\mu}}_k) = 0 \\ &\Rightarrow \bar{\mathbf{X}}_k - \hat{\boldsymbol{\mu}}_k = 0 \\ &\Rightarrow \hat{\boldsymbol{\mu}}_k = \bar{\mathbf{X}}_k \end{aligned}$$

■

Derivando em relação a $\boldsymbol{\Sigma}_k$, obtemos o estimador de máxima verossimilhança para a matriz de covariâncias:

$$\frac{\partial g}{\partial \boldsymbol{\Sigma}_k} = -\frac{n_k}{2} \boldsymbol{\Sigma}_k^{-1} + \frac{(n_k - 1)}{2} \boldsymbol{\Sigma}_k^{-1} \mathbf{S}_k \boldsymbol{\Sigma}_k^{-1} + \frac{n_k}{2} \boldsymbol{\Sigma}_k^{-1} (\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)(\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)^t \boldsymbol{\Sigma}_k^{-1}$$

Igualando a zero e substituindo o estimador de $\boldsymbol{\mu}_k$:

$$\begin{aligned} -\frac{n_k}{2} \hat{\boldsymbol{\Sigma}}_k^{-1} + \frac{(n_k - 1)}{2} \hat{\boldsymbol{\Sigma}}_k^{-1} \mathbf{S}_k \hat{\boldsymbol{\Sigma}}_k^{-1} + \frac{n_k}{2} \hat{\boldsymbol{\Sigma}}_k^{-1} (\bar{\mathbf{X}}_k - \bar{\mathbf{X}}_k)(\bar{\mathbf{X}}_k - \bar{\mathbf{X}}_k)^t \hat{\boldsymbol{\Sigma}}_k^{-1} &= \mathbf{0} \\ -\frac{n_k}{2} \hat{\boldsymbol{\Sigma}}_k^{-1} + \frac{(n_k - 1)}{2} \hat{\boldsymbol{\Sigma}}_k^{-1} \mathbf{S}_k \hat{\boldsymbol{\Sigma}}_k^{-1} &= \mathbf{0} \end{aligned}$$

Pré e pós multiplicando ambos os lados da equação acima por $\hat{\boldsymbol{\Sigma}}_k$, e resolvendo para $\hat{\boldsymbol{\Sigma}}_k$, temos:

$$\begin{aligned} \hat{\boldsymbol{\Sigma}}_k \hat{\boldsymbol{\Sigma}}_k^{-1} \hat{\boldsymbol{\Sigma}}_k &= \frac{(n_k - 1)}{n_k} \hat{\boldsymbol{\Sigma}}_k^{-1} \hat{\boldsymbol{\Sigma}}_k \mathbf{S}_k \hat{\boldsymbol{\Sigma}}_k^{-1} \hat{\boldsymbol{\Sigma}}_k \\ \hat{\boldsymbol{\Sigma}}_k &= \frac{n_k - 1}{n_k} \mathbf{S}_k = \frac{1}{n_k} \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \bar{\mathbf{X}}_k)(\mathbf{X}_{kj} - \bar{\mathbf{X}}_k)^t \end{aligned}$$

Substituindo os estimadores de máxima verossimilhança do vetor de médias e matriz de covariâncias na função de verossimilhança, obtemos seu máximo para o espaço irrestrito:

$$\begin{aligned}
L_{\Omega}(\mathbf{X}; \hat{\boldsymbol{\mu}}_k, \hat{\boldsymbol{\Sigma}}_k) &= (2\pi)^{-\frac{np}{2}} \prod_{k=1}^K |\hat{\boldsymbol{\Sigma}}_k|^{-\frac{n_k}{2}} \exp \left\{ -\frac{1}{2} \sum_{k=1}^K \text{tr}[(n_k - 1) \hat{\boldsymbol{\Sigma}}_k^{-1} \mathbf{S}_k + n_k \hat{\boldsymbol{\Sigma}}_k^{-1} (\bar{\mathbf{X}}_k - \bar{\mathbf{X}}_k)(\bar{\mathbf{X}}_k - \bar{\mathbf{X}}_k)^t] \right\} \\
&= (2\pi)^{-\frac{np}{2}} \prod_{k=1}^K |\hat{\boldsymbol{\Sigma}}_k|^{-\frac{n_k}{2}} \exp \left\{ -\frac{1}{2} \sum_{k=1}^K \text{tr} \left[(n_k - 1) \frac{n_k}{(n_k - 1)} \mathbf{S}_k^{-1} \mathbf{S}_k \right] \right\} \\
&= (2\pi)^{-\frac{np}{2}} \prod_{k=1}^K |\hat{\boldsymbol{\Sigma}}_k|^{-\frac{n_k}{2}} \exp \left\{ -\frac{1}{2} \sum_{k=1}^K n_k p \right\} \\
&= (2\pi)^{-\frac{np}{2}} \prod_{k=1}^K |\hat{\boldsymbol{\Sigma}}_k|^{-\frac{n_k}{2}} \exp \left\{ -\frac{np}{2} \right\}
\end{aligned}$$

Sob H_0 , a função de verossimilhança para o modelo restrito é dada por:

$$L_{\Omega_0}(\mathbf{X}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}) = (2\pi)^{-\frac{np}{2}} |\boldsymbol{\Sigma}|^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} \sum_{k=1}^K \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \boldsymbol{\mu}_k)^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_{kj} - \boldsymbol{\mu}_k) \right\}$$

e a função suporte, por:

$$g(\mathbf{X}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}) = -\frac{np}{2} \ln(2\pi) - \frac{n}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{k=1}^K \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \boldsymbol{\mu}_k)^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_{kj} - \boldsymbol{\mu}_k)$$

Da mesma forma, tem-se:

$$\sum_{k=1}^K \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \boldsymbol{\mu}_k)^t \boldsymbol{\Sigma}^{-1} (\mathbf{X}_{kj} - \boldsymbol{\mu}_k) = \sum_{k=1}^K \text{tr}[(n_k - 1) \boldsymbol{\Sigma}^{-1} \mathbf{S}_k + n_k \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)(\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)^t]$$

Logo, a função suporte pode ser reescrita como:

$$g(\mathbf{X}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}) = -\frac{np}{2} \ln(2\pi) - \frac{n}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{k=1}^K \text{tr}[(n_k - 1) \boldsymbol{\Sigma}^{-1} \mathbf{S}_k] - \frac{1}{2} \sum_{k=1}^K \text{tr}[n_k \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)(\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)^t]$$

Derivando a função suporte em relação ao vetor de médias temos:

$$\frac{\partial g}{\partial \boldsymbol{\mu}_k} = n_k \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k) \quad \text{para } k = 1, 2, \dots, K$$

Igualando a zero, temos o estimador de máxima verossimilhança da média da k -ésima população, dado por:

$$\begin{aligned}\frac{\partial g}{\partial \boldsymbol{\mu}_k} = \mathbf{0} &\Rightarrow n_k \boldsymbol{\Sigma}^{-1}(\bar{\mathbf{X}}_k - \hat{\boldsymbol{\mu}}_k) = \mathbf{0} \\ &\Rightarrow \bar{\mathbf{X}}_k - \hat{\boldsymbol{\mu}}_k = \mathbf{0} \\ &\Rightarrow \hat{\boldsymbol{\mu}}_k = \bar{\mathbf{X}}_k\end{aligned}$$

Derivando a função suporte em relação a $\boldsymbol{\Sigma}$, temos:

$$\frac{\partial g}{\partial \boldsymbol{\Sigma}} = -\frac{n}{2} \boldsymbol{\Sigma}^{-1} + \sum_{k=1}^K \frac{(n_k - 1)}{2} \boldsymbol{\Sigma}^{-1} \mathbf{S}_k \boldsymbol{\Sigma}^{-1} + \sum_{k=1}^K \frac{n_k}{2} \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)(\bar{\mathbf{X}}_k - \boldsymbol{\mu}_k)^t \boldsymbol{\Sigma}^{-1}$$

Igualando a zero e substituindo o estimador de máxima verossimilhança da média:

$$\begin{aligned}-\frac{n}{2} \hat{\boldsymbol{\Sigma}}^{-1} + \sum_{k=1}^K \frac{(n_k - 1)}{2} \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{S}_k \hat{\boldsymbol{\Sigma}}^{-1} + \sum_{k=1}^K \frac{n_k}{2} \hat{\boldsymbol{\Sigma}}^{-1} (\bar{\mathbf{X}}_k - \bar{\mathbf{X}}_k)(\bar{\mathbf{X}}_k - \bar{\mathbf{X}}_k)^t \hat{\boldsymbol{\Sigma}}^{-1} &= \mathbf{0} \\ -\frac{n}{2} \hat{\boldsymbol{\Sigma}}^{-1} + \sum_{k=1}^K \frac{(n_k - 1)}{2} \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{S}_k \hat{\boldsymbol{\Sigma}}^{-1} &= \mathbf{0}\end{aligned}$$

Pré e pós multiplicando ambos os lados da equação acima por $\hat{\boldsymbol{\Sigma}}_k$, e resolvendo para $\hat{\boldsymbol{\Sigma}}_k$, temos:

$$\begin{aligned}\sum_{k=1}^K (n_k - 1) \hat{\boldsymbol{\Sigma}} \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{S}_k \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\Sigma}} &= n \hat{\boldsymbol{\Sigma}} \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\Sigma}} \\ \hat{\boldsymbol{\Sigma}} &= \frac{\sum_{k=1}^K (n_k - 1) \mathbf{S}_k}{n} = \frac{\sum_{k=1}^K n_k \hat{\boldsymbol{\Sigma}}_k}{n}\end{aligned}$$

Assim, o máximo da função de verossimilhança para o modelo restrito será dado então, por:

$$\begin{aligned}\mathbf{L}_{\Omega_0}(\mathbf{X}; \hat{\boldsymbol{\mu}}_k, \hat{\boldsymbol{\Sigma}}) &= (2\pi)^{-\frac{np}{2}} |\hat{\boldsymbol{\Sigma}}|^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} \sum_{k=1}^K \text{tr}[(n_k - 1) \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{S}_k] - \frac{1}{2} \sum_{k=1}^K \text{tr}[n_k \hat{\boldsymbol{\Sigma}}^{-1} (\bar{\mathbf{X}}_k - \bar{\mathbf{X}}_k)(\bar{\mathbf{X}}_k - \bar{\mathbf{X}}_k)^t] \right\} \\ &= (2\pi)^{-\frac{np}{2}} |\hat{\boldsymbol{\Sigma}}|^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} \sum_{k=1}^K \text{tr} \left[(n_k - 1) \frac{n}{\sum_{k=1}^K (n_k - 1)} \mathbf{S}_k^{-1} \mathbf{S}_k \right] \right\} \\ &= (2\pi)^{-\frac{np}{2}} |\hat{\boldsymbol{\Sigma}}|^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} n \frac{\sum_{k=1}^K (n_k - 1)}{\sum_{k=1}^K (n_k - 1)} \text{tr}(\mathbf{I}) \right\} \\ &= (2\pi)^{-\frac{np}{2}} |\hat{\boldsymbol{\Sigma}}|^{-\frac{n}{2}} \exp \left\{ -\frac{np}{2} \right\}\end{aligned}$$

A estatística do teste de razão de verossimilhança é dada por:

$$\begin{aligned}\Lambda &= \frac{L_{\Omega_0}(\mathbf{X}; \hat{\boldsymbol{\mu}}_k, \hat{\boldsymbol{\Sigma}})}{L_{\Omega}(\mathbf{X}; \hat{\boldsymbol{\mu}}_k, \hat{\boldsymbol{\Sigma}}_k)} = \frac{(2\pi)^{-\frac{np}{2}} |\hat{\boldsymbol{\Sigma}}|^{-\frac{n}{2}} \exp\left\{-\frac{np}{2}\right\}}{(2\pi)^{-\frac{np}{2}} \prod_{k=1}^K |\hat{\boldsymbol{\Sigma}}_k|^{-\frac{n_k}{2}} \exp\left\{-\frac{n_k}{2}\right\}} \\ &= \frac{\prod_{k=1}^K |\hat{\boldsymbol{\Sigma}}_k|^{\frac{n_k}{2}}}{|\hat{\boldsymbol{\Sigma}}|^{\frac{n}{2}}}\end{aligned}$$

De forma que,

$$-2 \ln(\Lambda) = -2 \ln \left(\frac{\prod_{k=1}^K |\hat{\boldsymbol{\Sigma}}_k|^{\frac{n_k}{2}}}{|\hat{\boldsymbol{\Sigma}}|^{\frac{n}{2}}} \right) = - \left[\sum_{k=1}^K n_k \ln |\hat{\boldsymbol{\Sigma}}_k| - n \ln |\hat{\boldsymbol{\Sigma}}| \right]$$

possui assintoticamente distribuição qui-quadrado, sob H_0 , com $f = \frac{(k-1)p(p+1)}{2}$ graus de liberdade.

Dessa forma, podemos formular um teste de hipóteses

$$H_0 : \boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \dots = \boldsymbol{\Sigma}_k = \boldsymbol{\Sigma} \quad \text{vs} \quad H_a : \text{pelo menos uma difere}$$

Ao nível de significância α , rejeitamos H_0 em favor de H_a se observarmos

$$\chi_2 = - \left[\sum_{k=1}^K n_k \ln |\hat{\boldsymbol{\Sigma}}_k| - n \ln |\hat{\boldsymbol{\Sigma}}| \right] > \chi_f^2(\alpha)$$

de acordo com o Resultado 02. $\chi_f^2(\alpha)$ denota o $100(1-\alpha)$ -ésimo percentil superior de uma distribuição χ_f^2 , sendo $f = \frac{(k-1)p(p+1)}{2}$ gl.